



EDA: Análisis Exploratorio de Datos

De los datos a las decisiones — una guía práctica y aplicada al mundo empresarial

ANÁLISIS DE DATOS

MACHINE LEARNING

BUSINESS INTELLIGENCE

¿Para qué sirve el análisis de datos?

El análisis de datos transforma información en decisiones. Empresas de todos los sectores lo usan para **entender el pasado, anticipar el futuro y actuar con evidencia**, no con intuición.

 Sin análisis de datos, las decisiones empresariales se basan en suposiciones. Con él, se basan en **hechos medibles y reproducibles**.

Ventas

¿Qué productos venden más y en qué época del año?

Cliente

¿Qué segmentos tienen mayor tasa de abandono?

Finanzas

¿Dónde están los cuellos de botella en el margen?



Tipos de análisis de datos

Cada tipo responde a una pregunta diferente. En esta presentación nos centraremos en los dos primeros.

1

Descriptivo

¿Qué pasó?

Ventas del último trimestre, tasa de devoluciones, NPS promedio.

2

Predictivo

¿Qué va a pasar?

Modelos que anticipan churn, demanda o fraude.

3

Prescriptivo

¿Qué debería hacerse?

Optimización de precios, rutas logísticas, campañas personalizadas.

📌 **Foco de esta presentación:** Análisis **descriptivo** y **predictivo** — la base de cualquier proyecto de datos sólido.

Origen de los datos: el Data Warehouse

Un **Data Warehouse** es el repositorio centralizado donde se consolidan datos de distintas fuentes (CRM, ERP, web, etc.) para su análisis.

Todo dataset se estructura en dos tipos de campos fundamentales:



Métricas

Valores numéricos que se agregan y miden.

Ej: ventas €, unidades, ingresos, tasa de conversión



Dimensiones


Atributos que describen el contexto.

Ej: fecha, producto, región, canal de venta




La combinación de métricas y dimensiones permite hacer preguntas como: «¿Cuánto vendimos en el norte en Q3?»

El EDA dentro del proceso de Machine Learning



EDA & preparación

Limpieza, exploración e ingeniería de variables



Modelado

Entrenamiento, validación y despliegue del modelo

¿Por qué el EDA ocupa tanto tiempo?


1 Limpieza de datos
Nulos, duplicados y errores de formato que invalidan el modelo.

2 Comprensión del negocio
Entender qué significa cada variable y su relación con el objetivo.

3 Preparación de features
Transformar variables para que el algoritmo pueda aprender.

Tipos de variables

Identificar correctamente cada variable determina qué análisis aplicar y qué gráfico usar.



Cualitativa Nominal

Sin orden natural.


Ej: país, género, canal de venta



Cualitativa Ordinal

Con orden, sin distancia fija.


Ej: nivel educativo, satisfacción (1-5)



Cuantitativa Discreta

Valores enteros contables.

Ej: número de pedidos, hijos, visitas web



Cuantitativa Continua

Valores en un rango continuo.

Ej: temperatura, ingresos, tiempo de sesión

Exploración inicial del dataset

Primeras preguntas que hacemos

01

Dimensiones

¿Cuántas filas (observaciones) y columnas (variables) tiene?

02

Tipos de datos

¿Cada columna es del tipo correcto? ¿Hay fechas como texto?

03


Distribuciones

¿Cómo se distribuyen los valores? ¿Son normales, sesgados?

04

Valores únicos


¿Hay categorías inesperadas o valores fuera de rango?



i La **distribución normal** es la base estadística de muchos modelos. Si los datos no la siguen, puede ser necesario transformarlos.

Tratamiento de datos faltantes

Los **datos nulos** son observaciones sin valor registrado. Ignorarlos puede sesgar el análisis o romper el modelo. La estrategia depende del porcentaje de nulos y del tipo de variable.



Eliminación

Válida si los nulos son pocos (<5%) y aleatorios



Imputación

Sustituir por media, mediana o moda según la distribución



Imputación avanzada

Usar KNN o modelos para predecir el valor faltante

Outliers: datos atípicos

¿Qué son y por qué importan?

Un **outlier** es un valor que se aleja significativamente del resto. Pueden ser errores de registro, o fenómenos reales como una venta récord. En modelos predictivos, **distorsionan los parámetros** y reducen la precisión.

⚠ Un solo outlier puede desplazar la media varios puntos y engañar al modelo.

Técnicas de detección

1


IQR — Rango Intercuartílico

Outlier si el valor está fuera de $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$. Robusto frente a distribuciones no normales.

2

Boxplot (diagrama de caja)

Visualización que muestra mediana, cuartiles y valores extremos de forma inmediata.



Correlación y Análisis Predictivo

Correlación entre variables

La correlación mide la **relación lineal entre dos variables** (de -1 a $+1$). Ayuda a decidir qué variables conservar y cuáles eliminar antes de modelar.

Correlación **no** implica **causalidad**. Que dos variables se muevan juntas no significa que una cause la otra.

Por qué hacerlo?

Identificar dependencias lineales entre variables para eliminar datos redundantes y evitar la multicolinealidad.

✅ **EDA → Correlación → Patrones → Modelo → Decisión.** Este es el flujo que convierte datos en ventaja competitiva.

Ejemplo económico

Dólar $\uparrow$ $\rightarrow$ coste de materia prima importada $\uparrow$
Correlación positiva alta: ambas variables se mueven juntas.

Multicolinealidad

Si dos variables están muy correlacionadas entre sí, una puede eliminarse sin perder información.



Predicción de ventas

Anticipar demanda por región y temporada




Churn de clientes

Identificar clientes en riesgo de abandono

Correlación entre variables

r : Mide la relación lineal entre variables



Análisis Prescriptivo: ¿Qué debería hacerse?

El análisis prescriptivo va un paso más allá del predictivo. Utiliza los datos para recomendar acciones específicas que optimicen los resultados, respondiendo a la pregunta **«¿Qué debería hacerse?»**.



Recomienda Acciones

Sugiere el mejor curso de acción para lograr un objetivo.



Optimización

Encuentra la solución óptima entre diversas posibilidades.



Toma de Decisiones

Asiste en la formulación de estrategias proactivas.



Los análisis descriptivos y predictivos son la base para el análisis prescriptivo.

La Analogía del GPS

Para entender la diferencia entre los tipos de análisis, podemos usar un ejemplo muy familiar:



Análisis Descriptivo

El GPS te dice **dónde has estado** y tu posición actual. Describe tu trayectoria y tu ubicación en tiempo real.



Análisis Predictivo

El GPS te dice **dónde podrías estar**: al ritmo que vas y considerando el tráfico, estima que llegarás a las 6:00 PM.



Análisis Prescriptivo

El GPS te dice **qué deberías hacer**: "Hay un accidente más adelante; gira a la derecha en la próxima calle para ahorrar 10 minutos".

Esta progresión nos lleva desde entender el pasado hasta influir activamente en el futuro, transformando datos en decisiones estratégicas.