Santino Tacchini, Nicolas Echaniz, Justo Bullrich, Tomas Taboada, Federico Lieste y Manuel Vieytes

Actividad 1: - Grupo 6 - Data Big

Objetivos:

- Aplicar una visión integral del ecosistema de Big Data a escenarios reales.
- Conectar los conceptos teóricos (5 V's, almacenamiento, procesamiento, etc.) con sus aplicaciones prácticas.
- Fomentar el pensamiento crítico, la investigación y la colaboración en grupo.
- Desarrollar habilidades de presentación y comunicación de hallazgos.

Instrucciones para los Alumnos:

1. **Formación de Grupos:**
    - Utilizar los grupos ya creados en la clase anterior.
2. **Asignación del Caso de Estudio:**
    - A cada grupo se le asignará uno de los casos de uso real (se encuentran al final del documento).
3. **Investigación y Discusión:**
    - En tu grupo, analicen en profundidad el caso de estudio asignado.
    - Utilicen los siguientes puntos como guía para su análisis y tomen notas de sus respuestas:
    - **1. Las 5 V's del Big Data:**
        - **Volumen:** ¿Qué tipo de datos masivos se generan o manejan? ¿De qué escala hablamos (terabytes, petabytes)?
        - **Velocidad:** ¿Los datos se procesan en tiempo real o por lotes? ¿Por qué esa velocidad es crucial para el éxito de la empresa?
        - **Variedad:** ¿Qué tipos de datos se utilizan (estructurados, no estructurados, semi-estructurados)?
        - **Veracidad:** ¿Qué desafíos de calidad y confiabilidad de datos podrían enfrentar?
        - **Valor:** ¿Cuál es el beneficio de negocio (ganancias, eficiencia, satisfacción del cliente) que se obtiene del Big Data en este caso?
    - **2. Almacenamiento:**
        - ¿Dónde se almacenarán estos datos? ¿Creen que sería un sistema de archivos distribuido como HDFS, un Data Lake o una base de datos más tradicional?
        - ¿Qué desafíos de escalabilidad y costo enfrentarían al almacenar estos datos?
    - **3. Procesamiento y Análisis:**
        - ¿Qué tipo de procesamiento se necesita (por lotes o en streaming)?
        - ¿Qué herramientas de análisis serían las más adecuadas (ej. SQL, Python, machine learning)?
    - **4. Gobernanza y Seguridad:**
        - ¿Qué datos sensibles o personales podrían estar manejando? (ej. datos personales de clientes, historial de navegación)?
        - ¿Qué desafíos de seguridad y privacidad tendrían que considerar para proteger la información?
4. **Presentación de Hallazgos:**
    - Al finalizar el tiempo de discusión, cada grupo presentará un resumen de su análisis al resto de la clase. El objetivo es compartir una visión integral del caso de estudio, conectando todos los puntos analizados.

Caso de Estudio 6: Industria del Deporte de Alto Rendimiento

Caso de Uso: Optimización del rendimiento de atletas y prevención de lesiones. **Descripción Ampliada:** Equipos de la Formula 1, NBA y ligas de fútbol europeo utilizan Big Data para ganar una ventaja competitiva:

- **Sensores IoT (Wearables):** Los atletas usan dispositivos que miden pulsaciones, aceleración, calidad del sueño y niveles de fatiga en tiempo real. Un monoplaza de F1 genera gigabytes de datos por vuelta mediante cientos de sensores.
- **Análisis Predictivo de Lesiones:** Al cruzar datos de carga de entrenamiento con historiales médicos, los algoritmos pueden alertar cuándo un jugador tiene un alto riesgo de lesionarse, permitiendo al entrenador darle descanso preventivo.
- **Estrategia de Juego:** Se analizan videos y datos de posicionamiento GPS para entender patrones del rival y decidir, por ejemplo, hacia qué lado es más probable que un arquero se tire en un penal.

1. Las 5 Vs de Big Data:

Volumen: Los datos generados alcanzan una escala masiva , midiendo grandes cantidades de información por cada evento deportivo. Se generan datos biométricos (pulsaciones, fatiga), cinemáticos (aceleración, posicionamiento GPS), técnicos (sensores en autos de F1) y visuales (análisis de video de partidos). Hablamos de Terabytes, un solo monoplaza de F1 genera gigabytes por vuelta; si sumamos toda una temporada de múltiples equipos y ligas, el volumen es masivo. Un auto puede tener entre 200 y 300 sensores, y puede generar varios gigabytes de datos por carrera o incluso por vuelta dependiendo del equipo y del sistema de telemetría.

Velocidad: Principalmente se generan en tiempo real. Es crucial porque permite tomar decisiones inmediatas. En la F1, ayuda a decidir una parada en pits, para esto debemos medir el estado general del vehículo como adherencia de las cubiertas y determinar un cambio estratégico contemplando el valor en tiempo real del estado del vehículo; en el fútbol o la NBA, permite a un entrenador retirar a un jugador que muestra signos de fatiga extrema antes de que ocurra una lesión.

Variedad:

- Estructurados: Datos numéricos de sensores (frecuencia cardíaca, velocidad en km/h).

En la Fórmula 1, la mayoría de los datos provenientes de sensores son estructurados.

Ejemplos

Datos del motor

- RPM del motor

- temperatura del motor

- presión de aceite
- consumo de combustible

Datos de neumáticos

- temperatura del neumático
- presión del neumático
- nivel de desgaste

Datos de conducción

- posición del acelerador
- presión del freno
- ángulo del volante
- cambio de marcha

Datos del vehículo

- velocidad del auto
- fuerzas G
- altura del chasis
- movimiento de la suspensión

Datos de telemetría

- tiempos de vuelta
- tiempos por sector
- posición GPS
- distancia con otros autos

- No estructurados: Videos de partidos y entrenamientos.

Ejemplos en Fórmula 1

Videos

- grabaciones onboard del piloto
- cámaras del circuito
- grabaciones de entrenamientos

Imágenes

- fotos del comportamiento aerodinámico
- análisis visual de neumáticos

Audio

- comunicaciones por radio entre piloto e ingenieros

Documentos y reportes

- informes técnicos de ingenieros
- reportes de rendimiento del piloto
- diagnósticos mecánicos

Estos datos suelen almacenarse en **data lakes** y requieren herramientas de análisis más complejas.

- Semi-estructurados**:** Historiales médicos digitales y reportes de rendimiento que combinan texto con métricas fijas.

Veracidad: La precisión de los sensores (un GPS con margen de error puede falsear la distancia recorrida) y la calidad de los datos biométricos (interferencia en la señal). La confiabilidad es vital, ya que un dato falso podría llevar a un diagnóstico médico erróneo o a una estrategia de juego fallida.

Valor:

- Beneficio: El valor principal es la ventaja competitiva, esto impactará directamente en los resultados del equipo y por lo tanto los ingresos de este. Además de la eficiencia operativa al tener una mentalidad orientada a la toma de decisiones por datos y no sentimientos o subjetividades.

- Ganancias: Menos lesiones significan que los activos más caros (los jugadores) están más tiempo en la cancha. Por otro lado, los ingresos que se generen por ganar torneos o competencias, además de los mayores ingresos publicitarios ya que se pueden conseguir mejores patrocinadores si los resultados son mejores o se clasifican/ganan torneos importantes.
- Eficacia: Mayor probabilidad de ganar partidos mediante el análisis de patrones del rival (como el lado al que se lanza un arquero).

2. Almacenamiento:

En cuanto al almacenamiento creemos que el lugar más adecuado creemos que es data lake. Esto permite almacenar la inmensa cantidad de datos crudos de forma flexible y a un costo menor, para posteriormente cuando sea necesario utilizarlos (para un partido o cuando queramos ver el estado de los jugadores), llevarlos a un data warehouse para procesarlos más rápidamente.
En cuanto al desafío de escalabilidad de datos y costos, nosotros creemos el que principal reto operativo es gestionar los picos masivos de generación de datos durante los fines de semana de competición y la acumulacion histórica a lo largo de los años. Se requiere una arquitectura elástica que permita escalar el almacenamiento en momentos de pico sin incurrir en costos desproporcionados por mantener información histórica inactiva ya que creemos que la información histórica tiene gran relevancia para futuros encuentros/carreras, ya sea que volvamos a competir en el mismo circuito o contra el mismo equipo o contra el mismo director técnico.

3. Procesamiento y análisis:

En este caso el procesamiento por streaming sería la mejor opción, esto se debe a que el streaming resulta vital para aplicaciones que requieren de respuestas inmediatas a la hora de tomar datos, esto se evidencia cuando se habla de sensores en los monoplazas y pilotos o en los monoplazas en donde estos sensores deben dar respuestas inmediatas para así generar el dato. Además, en estos casos, el procesamiento debe realizarse en el momento, ya sea con una estrategia en la F1 o para una decisión de un árbitro, por esto también, elegimos el streaming como opción.

Por otro lado, las mejores herramientas para este caso serían machine learning e IA, esto se debe a que estas se utilizan para encontrar patrones complejos y hacer predicciones. Eso es justamente lo que necesitamos en nuestro caso ya que para el análisis predictivo de lesiones, esto resulta ideal para analizar los patrones o rasgos que se presentan previos a una lesión mediante machine learning y prevenirlos con un descanso o tratamiento preventivo (como dice la consigna). Además, estas herramientas también resultan vitales para el análisis del juego, ya que estas permiten analizar patrones complejos, esto sirve para analizar el estilo de juego del rival y, al analizar otros partidos en donde el rival haya sido vencido, detectar patrones comunes para poder derrotarlos con esos datos.

4. Gobernanza y seguridad:

Datos sensibles manejados

- Datos personales de salud: Frecuencia cardíaca, presión arterial, historiales médicos con diagnósticos y tratamientos, etc.
- Datos biométricos: Patrones de sueño, niveles de fatiga, composición corporal, etc.
- Datos de localización: Coordenadas GPS que revelan ubicaciones privadas durante entrenamientos.
- Información contractual: Datos de rendimiento vinculados a cláusulas económicas.
- Tecnología/blueprints e I + D: Los blueprints de diseños, desarrollos tecnológicos e investigaciones, resultan vitales para mantenerse por encima de la competencia, por lo que deben ser cuidadosamente almacenados y compartidos.

Estos datos están protegidos por regulaciones como GDPR en Europa e HIPAA en contextos estadounidenses donde se manejan datos de salud.

Desafíos de seguridad y privacidad. Riesgos:

- Los sensores wearables pueden ser puntos de entrada para ciberataques.
- Brechas de confidencialidad: Filtraciones podrían exponer condiciones médicas privadas o estrategias competitivas. Es vital que la información histórica de nuestro equipo y rivales posean un mayor nivel de seguridad, esto es para que no solamente no expongan las tácticas de nuestro equipo a rivales, sino que también para que los rivales no vean entrenamientos propios y estudien los patrones y tendencias naturales de nuestros jugadores y las usen para vencernos.
- Uso indebido de datos: Riesgo de que datos de rendimiento se utilicen de forma discriminatoria en negociaciones contractuales. Además, que otros equipos utilicen información de nuestros jugadores en nuestra contra (fichajes por ejemplo)

Medidas de protección necesarias

1. Encriptación end-to-end.
2. Control de Acceso Basado en Roles (RBAC): Limita quién puede acceder a qué información según función laboral y su rango dentro de la organización.
3. Auditorías regulares. Registros de acceso. Chequeos mensuales/semanales de accesos por cada perfil, puede hacerse mediante un bot u otra herramienta digital para no tener que utilizar personal, y que el personal solamente aparezca una vez que haya alguna irregularidad con respecto a la normalidad.
4. Compliance más profundo. Cumplimiento de regulaciones deportivas internacionales y leyes de protección de datos.
5. Federated Learning: Técnica utilizada en Fórmula 1 donde modelos de machine learning se entrenan sin compartir datos crudos entre equipos, preservando secretos competitivos.